

Lista artykułów wybranych w procesie SLR

Legenda: ★ — wybrano do pełnej ekstrakcji danych (6 artykułów) ❄️ — artykuł pozyskany w procesie snowballingu

Poniższa lista zawiera 19 artykułów zidentyfikowanych w procesie przeglądu systematycznego literatury (SLR) dotyczącego tematu: *Modele LLM jako uniwersalne agenty adaptujące się do systemów złożonych na przykładzie gier planszowych*. Spośród 147 unikalnych pozycji znalezionych w bazach danych, po selekcji i pełnej lekturze do analizy włączono 16 artykułów z wyszukiwania oraz 3 artykuły ze snowballingu. Z tej puli 6 artykułów wybrano do pełnej ekstrakcji danych ze względu na ich bezpośrednie powiązanie z hipotezą badawczą.

Artykuły z wyszukiwania (16)

1. ★ [1] — **Optimizing LLM Strategies for Playing Mendikot using Prompt Engineering**

Artykuł bada optymalizację strategii modelu GPT-4o w tradycyjnej indyjskiej grze karcianej Mendikot. Autorzy wykazali, że zaawansowana inżynieria promptów (uczenie na wzorcach eksperckich, dynamiczna modyfikacja promptów) podniosła odsetek wygranych z 45% do 65% bez zmiany samego modelu.

Wybrano do ekstrakcji — bezpośrednio dotyczy poprawy gry agenta LLM przez prompt engineering, co jest kluczowe dla projektu adaptacji do gier planszowych.

2. ★ [2] — **Strategic Behavior of Large Language Models and the Role of Game Structure versus Contextual Framing**

Badanie porównuje zachowania strategiczne modeli GPT-4 i LLaMA-2-70B w czterech grach z teorii gier (Dylemat Więźnia, Stag Hunt, Snowdrift, Prisoner's Delight) pod kątem wpływu struktury gry vs. kontekstowego sformułowania scenariusza. GPT-4 reaguje silniej na strukturę wypłat, natomiast LLaMA-2 — na narracyjny kontekst.

Wybrano do ekstrakcji — odkrycie fundamentalnej rozbieżności w przetwarzaniu informacji strategicznej między modelami ma bezpośrednie przełożenie na projektowanie promptów dla gier planszowych.

3. ★ [3] — **Adaptive Command: Real-Time Policy Adjustment via Language Models in StarCraft II**

Artykuł analizuje zdolność agentów LLM (GPT-4, Claude 2, Gemini Pro) do adaptacji strategii w czasie rzeczywistym w StarCraft II. Modele skutecznie korygowały politykę działania w odpowiedzi na zmieniający się stan gry bez konieczności ponownego trenowania.

Wybrano do ekstrakcji — demonstruje zdolność LLM do dynamicznej adaptacji w złożonych środowiskach gier, co jest analogiczne do wymagań gier planszowych.

4. ★ [4] — **Strategic Learning Under Linguistic and Contextual Constraints**

Praca przedstawia formalny model matematyczny (Context-Constrained Nash Equilibrium) opisujący wpływ ograniczeń okna kontekstowego na uczenie się strategiczne. Zidentyfikowano przejścia fazowe przy 4096 tokenach kontekstu, poniżej których skuteczność agenta drastycznie spada, oraz trzy reżimy operacyjne.

Wybrano do ekstrakcji — wyniki bezpośrednio determinują, jak kompresować lub segmentować instrukcje gier planszowych dla agenta LLM.

5. ★ [5] — **LLMs and Generative Agent-Based Models for Complex Systems Research**

Obszerny przegląd zastosowań LLM i generatywnych modeli agentowych (GABM) w bada-

niach nad systemami złożonymi, obejmujący sieci złożone, teorię gier i dynamikę społeczną. Kluczowe odkrycie: LLM są nadmiernie kooperatywne w Dylemacie Więźnia (65,4% vs 37% u ludzi), a GPT-4 w wariantcie iterowanym stosuje strategię *unforgiving tit-for-tat*.
Wybrano do ekstrakcji — kompleksowo dokumentuje systematyczne uprzedzenia behawioralne LLM w grach, które muszą być uwzględnione przy projektowaniu agenta.

6. ★ [6] — **Playing Games with Large Language Models: Randomness and Strategy**
Badanie zdolności GPT-4o-mini do gry w Kamień-Papier-Nożyce i Dylemat Więźnia. Model wykazywał silne uprzedzenia w generowaniu losowych wyborów, rozwijał strategie unikania przegranej (loss aversion), a rozgrywki RPS szybko zbiegały do patowej powtarzalności.
Wybrano do ekstrakcji — ujawnia fundamentalne ograniczenie LLM w grach wymagających losowości, co implikuje potrzebę zewnętrznego generatora losowości.
7. [7] — *Evolvability in Self-Amendment Games with LLM Agents*
Artykuł bada zdolność agentów LLM do modyfikowania reguł gry w trakcie jej trwania, inspirowany mechaniką gry Nomic. Agenty proponują, głosują i wdrażają zmiany reguł, badając emergentne zachowania w ewoluującym środowisku.
Odrzucono z ekstrakcji — koncentruje się na meta-grze (tworzenie reguł), nie na adaptacji do istniejących reguł gier planszowych.
8. [8] — *Personality-Aware LLM Agents in Polymatrix Games*
Praca bada wpływ cech osobowości Big Five na zachowania strategiczne agentów LLM w grach wielomacierzowych (polymatrix games). Demonstrowane jest, jak różne profile osobowościowe wpływają na kooperację i rywalizację.
Odrzucono z ekstrakcji — skupia się na modelowaniu osobowości, a nie na mechanizmach adaptacji do reguł gier.
9. [9] — *Effect of Private Deliberation on Deception in Repeated Games*
Badanie analizuje wpływ prywatnej deliberacji (wewnętrznego rozumowania) na skłonność agentów LLM do oszustwa w powtarzanych grach strategicznych. Wykazano, że dostęp do fazy deliberacji zmienia profil decyzyjny agenta.
Odrzucono z ekstrakcji — dotyczy mechanizmów oszustwa i deliberacji, nie bezpośrednio adaptacji do gier planszowych.
10. [10] — *B3Emo: Quantifying Affect as a Double-Edged Sword in Strategic LLM Interactions*
Framework B3Emo kwantyfikuje rolę emocjonalnego rozumowania w strategicznych interakcjach agentów LLM. Autorzy pokazują, że emocje mogą zarówno poprawiać, jak i pogarszać jakość decyzji strategicznych modeli.
Odrzucono z ekstrakcji — koncentruje się na afekcie i emocjach w grach, a nie na mechanizmach adaptacji do reguł.
11. [11] — *LLM-Driven Social Influence for Cooperative Behavior in Multi-Agent Systems*
Artykuł bada, jak agenty sterowane przez LLM mogą wywierać wpływ społeczny na inne agenty w systemach wieloagentowych w celu promowania zachowań kooperacyjnych. Przedstawiona jest analiza mechanizmów perswazji i wpływu w kontekście MAS.
Odrzucono z ekstrakcji — dotyczy wpływu społecznego i perswazji, nie adaptacji strategicznej w grach planszowych.
12. [12] — *Intelligent Games and Multi-Agent Deep Reinforcement Learning: A Review*
Przegląd metod głębokiego uczenia ze wzmocnieniem w środowiskach wieloagentowych (MADRL) w grach inteligentnych. Artykuł obejmuje szerokie spektrum metod RL, ale nie

koncentruje się na modelach językowych.

Odrzucono z ekstrakcji — dotyczy głównie MADRL, nie agentów opartych na LLM.

13. [13] — *Promoting Cooperation in the Public Goods Game Using Artificial Intelligent Agents*
Badanie wykorzystuje ewolucyjną teorię gier i modelowanie komputacyjne do analizy, jak agenty AI mogą promować kooperację w grze o dobra publiczne. Wykazano, że agenty naśladujące zachowanie ludzkie (mimicking) skutecznie obniżają próg kooperacji, w przeciwieństwie do wymuszanej kooperacji.
Odrzucono z ekstrakcji — stosuje metody ewolucyjne, nie LLM; dotyczy kooperacji w abstrakcyjnych grach, nie adaptacji do gier planszowych.
14. [14] — *(Ir)rationality in AI: State of the Art, Research Challenges and Open Questions*
Obszerny przegląd koncepcji racjonalności i irracjonalności w AI, obejmujący definicje z ekonomii, filozofii i psychologii. Autorzy analizują, kiedy irracjonalne zachowanie agentów może prowadzić do optymalnych wyników oraz jak identyfikować i interagować z irracjonalnymi agentami.
Odrzucono z ekstrakcji — artykuł przeglądowy o charakterze teoretycznym, nie dotyczy bezpośrednio gier planszowych ani adaptacji agentów.
15. [15] — *Predictive Analysis and Play Evaluation with Machine Learning*
Rozdział książkowy omawiający zastosowanie uczenia maszynowego w predykcyjnej analizie sportowej: klasyfikacja zagrań, klasteryzacja zachowań, ewaluacja przestrzeni i analiza kontrafaktyczna w sportach zespołowych (piłka nożna, koszykówka).
Odrzucono z ekstrakcji — dotyczy analityki sportowej z użyciem ML, nie agentów LLM ani gier planszowych.
16. [16] — *Evaluating Fairness in LLM Negotiator Agents via Economic Games Using Multi-Agent Systems*
Badanie sprawiedliwości agentów negocjacyjnych opartych na ChatGPT-4 Turbo w grach kupujący-sprzedający. Wykazano, że świadomość płci i rasy partnera wpływa na wyniki negocjacji, a kondycjonowanie osoby agenta może łagodzić te uprzedzenia.
Odrzucono z ekstrakcji — dotyczy sprawiedliwości i uprzedzeń w negocjacjach, nie adaptacji strategicznej w grach planszowych.

Artykuły ze snowballingu (3)

17. ❄️ [17] — *ALYMPICS: LLM Agents Meet Game Theory*
Praca wprowadza platformę ALYMPICS — systematyczny framework symulacyjny wykorzystujący agentów LLM (GPT-4) do badań z zakresu teorii gier. W pilotażowym studium „Water Allocation Challenge”, agenty uczestniczą w wielorundowych aukcjach o ograniczone zasoby, demonstrując zachowania strategiczne zbliżone do ludzkich.
Nie wybrano do ekstrakcji — pionierska platforma badawcza, ale koncentruje się na aukcjach zasobowych, nie na adaptacji do gier planszowych.
18. ❄️ [18] — *Strategic Behavior of Large Language Models: Game Structure vs. Contextual Framing*
Wcześniejsza wersja badań Lorè i Heydariego, stanowiąca punkt odniesienia dla późniejszej publikacji z 2024 roku. Analizuje zachowania GPT-3.5, GPT-4 i LLaMA-2 w czterech grach z teorii gier, badając wpływ kontekstu narracyjnego na podejmowanie decyzji strategicznych.
Nie wybrano do ekstrakcji — wyniki rozwinięte i zaktualizowane w późniejszej wersji [2], która została wybrana.

19. ❄️ [19] — *Emergent Cooperation and Strategy Adaptation in Multi-Agent Systems: An Extended Coevolutionary Theory with LLMs*

Artykuł proponuje Extended Coevolutionary (EC) Theory — framework integrujący dynamikę koewolucyjną, adaptacyjne uczenie się i rekomendacje strategiczne oparte na LLM (GPT-3.5-turbo) do modelowania interakcji w systemach wieloagentowych. Symulacje pokazują potencjał LLM w promowaniu kooperacji i budowaniu odporności strategicznej.

Nie wybrano do ekstrakcji — praca głównie teoretyczna, proponuje framework, ale bez empirycznej walidacji w środowisku gier planszowych.

- [1] A. J. -, „Optimizing LLM Strategies for Playing Mendikot using Prompt Engineering”, *IJFMR*, t. 6, nr 6, s. 30130, lis. 2024, doi: 10.36948/ijfmr.2024.v06i06.30130.
- [2] N. Lorè i B. Heydari, „Strategic behavior of large language models and the role of game structure versus contextual framing”, *Sci Rep*, t. 14, nr 1, s. 18490, sie. 2024, doi: 10.1038/s41598-024-69032-z.
- [3] W. Ma, D. Xu, S. Lin, H. Zhang, i J. Wang, „Adaptive Command : Real-Time Policy Adjustment via Language Models in StarCraft II”, w *Proceedings of the 2024 Sixth International Conference on Distributed Artificial Intelligences*, Singapore Singapore: ACM, grud. 2024, s. 22–30. doi: 10.1145/3719545.3721029.
- [4] S. Yoon, „Strategic Learning Under Linguistic and Contextual Constraints: A Theoretical Framework for LLM-Based Multi-Agent Coordination”, *IEEE Access*, t. 13, s. 197053–197071, 2025, doi: 10.1109/ACCESS.2025.3628927.
- [5] Y. Lu, A. Aleta, C. Du, L. Shi, i Y. Moreno, „LLMs and generative agent-based models for complex systems research”, *Physics of Life Reviews*, t. 51, s. 283–293, grud. 2024, doi: 10.1016/j.plprev.2024.10.013.
- [6] A. Vidler i T. Walsh, „Playing games with Large language models: Randomness and strategy”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2503.02582>
- [7] K. Horibe, „Evolvability in Rule-Making: A Self-Amendment Game Among LLM Agents”, w *Proceedings of the Genetic and Evolutionary Computation Conference Companion*, NH Malaga Hotel Malaga Spain: ACM, lip. 2025, s. 2127–2137. doi: 10.1145/3712255.3734367.
- [8] R. Hadfi i Y. J. Huang, „Personality-Aware Multiagent Large Language Models for Strategic Interactions in Polymatrix Games”, w *Proceedings of the 13th International Conference on Human-Agent Interaction*, Yokohama Japan: ACM, lis. 2025, s. 521–523. doi: 10.1145/3765766.3765856.
- [9] K. Poje, M. Brcic, M. Kovac, i M. B. Babac, „Effect of Private Deliberation: Deception of Large Language Models in Game Play”, *Entropy*, t. 26, nr 6, s. 524, cze. 2024, doi: 10.3390/e26060524.
- [10] A. Stepin *et al.*, „B3Emo: Quantifying Affect as a Double-Edged Sword in Strategic LLM Interactions”, *IEEE Access*, s. 1, 2026, doi: 10.1109/ACCESS.2026.3673221.
- [11] J. De Curtò i I. De Zarzà, „LLM-Driven Social Influence for Cooperative Behavior in Multi-Agent Systems”, *IEEE Access*, t. 13, s. 44330–44342, 2025, doi: 10.1109/ACCESS.2025.3548451.
- [12] Y. Wang, Y. Wang, F. Tian, J. Ma, i Q. Jin, „Intelligent games meeting with multi-agent deep reinforcement learning: a comprehensive review”, *Artif Intell Rev*, t. 58, nr 6, s. 165, mar. 2025, doi: 10.1007/s10462-025-11166-1.
- [13] A. Hintze i C. Adami, „Promoting cooperation in the public goods game using artificial intelligent agents”, *npj Complex*, t. 3, nr 1, s. 3, sty. 2026, doi: 10.1038/s44260-025-00065-9.
- [14] O. Macmillan-Scott i M. Musolesi, „(Ir)rationality in AI: state of the art, research challenges and open questions”, *Artif Intell Rev*, t. 58, nr 11, s. 352, sie. 2025, doi: 10.1007/s10462-025-11341-4.

- [15] K. Fujii, „Predictive Analysis and Play Evaluation with Machine Learning”, *Machine Learning in Sports*. Springer Nature Singapore, Singapore, s. 59–84, 2025. doi: 10.1007/978-981-96-1445-5_3.
- [16] A. Mouri Zadeh Khaki i A. Choi, „Evaluating Fairness in LLM Negotiator Agents via Economic Games Using Multi-Agent Systems”, *Mathematics*, t. 14, nr 3, s. 458, sty. 2026, doi: 10.3390/math14030458.
- [17] S. Mao *et al.*, „ALYMPICS: LLM Agents Meet Game Theory – Exploring Strategic Decision-Making with AI Agents”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2311.03220>
- [18] N. Lorè i B. Heydari, „Strategic Behavior of Large Language Models: Game Structure vs. Contextual Framing”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2309.05898>
- [19] I. De Zarzà, J. De Curtò, G. Roig, P. Manzoni, i C. T. Calafate, „Emergent Cooperation and Strategy Adaptation in Multi-Agent Systems: An Extended Coevolutionary Theory with LLMs”, *Electronics*, t. 12, nr 12, s. 2722, cze. 2023, doi: 10.3390/electronics12122722.