

Raport z systematycznego przeglądu literatury

Modele LLM jako uniwersalne agenty adaptujące się do systemów złożonych na przykładzie gier planszowych

Krzysztof Nasuta, Bartłomiej Krawisz
Filip Dawidowski, Stanisław Nieradko

2 kwietnia 2026

Opiekun: dr inż. Krzysztof Manuszewski

Plan prezentacji

Plan prezentacji	1	Wyniki liczbowe	15
Projekt badawczy	3	Wybrane artykuły do analizy	16
Cele i krótki opis	4	Snowballing i statystyki	17
Plan systematycznego przeglądu literatury		Wstępna ekstrakcja danych (1/2)	18
(SLR)	5	Wstępna ekstrakcja danych (2/2)	19
Cele i pytania badawcze	6	Wnioski	20
Słowa kluczowe	7	Proces SLR	21
Zapytania wyszukiwarkowe (Search		Wniosek 1: Prompt > Model	22
Strings)	8	Wniosek 2: Systematyczne	
Bazy danych i kryteria	9	uprzedzenia	23
Kryteria oceny jakości (QA) – Część I .	10	Wniosek 3: Paradoks złożoności	24
Kryteria oceny jakości (QA) – Część II .	11	Wniosek 4: Wybór modelu ma	
Proces SLR (Etap I)	12	znaczenie	25
Proces SLR (Etap II)	13	Rekomendacje dla projektu	26
Wyniki przeglądu literatury (SLR)	14	Dziękujemy za uwagę!	27

Bibliografia	28
--------------------	----

Projekt badawczy

Cel główny: Opracowanie agenta wykorzystującego duże modele językowe (LLM), zdolnego do prowadzenia rozgrywki w gry planszowe wyłącznie na podstawie analizy ich instrukcji.

Opis projektu:

- Symulacja zachowania żywego gracza w złożonych, dynamicznych systemach decyzyjnych.
- Skuteczna interakcja agent–środowisko (reprezentacja stanu gry, rejestrowanie ruchów przeciwników).
- Podejście iteracyjne (początkowo gry o prostszej mechanice).

Hipoteza badawcza: Weryfikacja możliwości skutecznego adaptowania się agenta LLM do reguł gry oraz podejmowania trafnych decyzji na podstawie znajomości samej instrukcji tekstowej.

Plan systematycznego przeglądu literatury (SLR)

- Zidentyfikowanie i analiza istniejących badań dotyczących wykorzystania LLM jako agentów decyzyjnych w systemach złożonych.
- Identyfikacja technik oceny skuteczności agentów LLM w zadaniach strategicznych.
- Zapoznanie się ze sposobami przekazywania informacji o systemie złożonym do agenta AI.
- Zidentyfikowanie ograniczeń, wyzwań oraz luk badawczych.

Związane z LLM:

- *large language model(s)*
- *LLM*
- *foundation models*
- *language model agents*
- *transformer models*

Adaptacja i systemy złożone:

- *complex / adaptive systems*
- *multi-agent systems*
- *dynamic environments*
- *strategic decision making*

Agenci i decyzje:

- *LLM agents*
- *autonomous / AI agents*
- *agent-based systems*
- *decision making / planning*
- *reasoning / tool-augmented LLM*

Gry strategiczne:

- *board / strategic games*
- *game environments*
- *game-playing agents*
- *AI in games / game AI*
- *game theory*

Zapytania wyszukiwarkowe (Search Strings)

```
("large language model" OR "large language models" OR "LLM" OR "foundation models" OR "language model agents" OR "transformer models")
```

AND

```
("LLM agents" OR "autonomous agents" OR "AI agents" OR "agent-based systems" OR "decision making" OR "planning" OR "reasoning" OR "tool-augmented LLM" OR "LLM-based agents" OR "artificial intelligence")
```

AND

```
("complex systems" OR "adaptive systems" OR "multi-agent systems" OR "dynamic environments" OR "environment interaction" OR "strategic decision making")
```

AND

```
("board games" OR "game environments" OR "strategic games" OR "game-playing agents" OR "AI in games" OR "game AI" OR "game theory")
```

Bazy danych:

- **Katalog BPG** – zasoby Biblioteki Politechniki Gdańskiej.
- **IEEEXplore** – publikacje z zakresu informatyki i nowych technologii.
- **SpringerLink** – czasopisma i materiały konferencyjne.

Kryteria selekcji:

- **Kryteria włączenia:** Publikacje od 2024 roku, język angielski lub polski.
- **Kryteria wykluczenia:** Publikacje niedostępne w ramach Otwartego Dostępu (Open Access).

- **QA1:** Czy praca opiera się na badaniach empirycznych (nie tylko teoretycznych)?
- **QA2:** Czy cele dotyczące adaptacji LLM do systemów są jasne określone?
- **QA3:** Czy opis środowiska gry lub systemu złożonego jest adekwatny?
- **QA4:** Czy architektura agenta i strategia promptingu były odpowiednie do celów?
- **QA5:** Czy metoda ewaluacji (np. win rate) była właściwa do oceny wydajności?
- **QA6:** Czy określono jasną bazę porównawczą (np. tradycyjne AI, człowiek)?


- **QA7:** Czy dane dotyczące wnioskowania LLM były zbierane w rygorystyczny sposób?
- **QA8:** Czy analiza zachowania i wydajności agenta była wystarczająco wnikliwa?
- **QA9:** Czy uwzględniono ograniczenia modelu (hallucynacje, okno kontekstowe, koszty)?
- **QA10:** Czy sformułowano jasne wnioski dotyczące zdolności adaptacji na podstawie tekstu?
- **QA11:** Czy badanie ma wartość dla rozwoju agentów w strategicznych grach planszowych?

1. **Planowanie:** Wspólne ustalenie pytań oraz celów ekstrakcji.
2. **Wybór baz artykułów:** Katalog BPG, IEEEExplore, SpringerLink.
3. **Doprecyzowanie zapytań:** Finalizacja struktur logicznych Search Strings.
4. **Walidacja kryteriów:** Dostosowanie kryteriów włączenia i wykluczenia.
5. **Pozyskanie wyników:** Pobranie surowych danych z wybranych baz.
6. **Usuwanie duplikatów:** Wykorzystanie programu Zotero.

7. **Selekcja (Screening):** Analiza tytułów i streszczeń w Zotero.
8. **Selekcja pełnotekstowa:** Szczegółowa lektura i weryfikacja przez członków zespołu.
9. **Snowballing:** Metoda **backward snowballing** (analiza bibliografii).
10. **Ekstrakcja i synteza:** Zestawienie celów, modeli i wniosków w arkuszu danych.
11. **Raportowanie:** Przygotowanie końcowego zestawienia wyników.

Wyniki przeglądu literatury (SLR)

Baza danych	Znalezione	Po deduplikacji	Screening	Full-text
IEEEExplore	3	3	3	2
Katalog BPG	47	45	12	5
SpringerLink	99	99	20	8
Suma	149	147	35	15



- [1] – Optymalizacja strategii LLM w grze Mendikot przy użyciu inżynierii promptów.
- [2] – Badanie zachowań strategicznych LLM i roli struktury gry vs. kontekstu.
- [3] – Adaptacyjne sterowanie i korekta polityki w czasie rzeczywistym w StarCraft II.
- [4] – Ewolucyjność w tworzeniu reguł w grach między agentami LLM.
- [5] – Wielozadaniowe modele LLM uwzględniające osobowość w interakcjach strategicznych.
- [6] – Wpływ prywatnej deliberacji na skłonność do oszustw w rozgrywkach LLM.
- [7] – Kwantyfikacja afektu jako obosiecznego miecza w strategicznych interakcjach LLM.
- [8] – Strategiczne uczenie się pod ograniczeniami lingwistycznymi i kontekstowymi.
- [9] – Wpływ społeczny sterowany przez LLM na zachowania kooperacyjne.
- [10] – Przegląd inteligentnych gier i głębokiego wzmocnionego uczenia wieloagentowego.
- [11] – Promowanie kooperacji w grach o dobra publiczne przy użyciu agentów AI.
- [12] – (Ir)racjonalność w AI: stan wiedzy i otwarte pytania badawcze.
- [13] – Predykcyjna analiza i ewaluacja rozgrywki z wykorzystaniem uczenia maszynowego.
- [14] – Ewaluacja sprawiedliwości agentów negocjacyjnych LLM w grach ekonomicznych.
- [15] – LLM i generatywne modele agentowe w badaniach nad systemami złożonymi.
- [16] – Losowość i strategia w grach LLM: awersja do straty i uprzedzenia stochastyczne.

Kluczowe publikacje z 2023 r. (backward snowballing):

- [17] – Platforma ALYMPICS — jeden z pierwszych testów strategicznych dla agentów LLM.
- [18] – Wcześniejsza wersja badań nad wpływem struktury gry na zachowanie modeli.
- [19] – Kooperacja emergentna w MAS — fundament dla nowszych badań dynamiki wieloagentowej.

Statystyka publikacji:

- Większość analizowanych prac pochodzi z lat 2024–2025.
- Główne tematy: kooperacja w MAS, ewaluacja zdolności strategicznych, inżynieria promptów dla złożonych procesów decyzyjnych.

Włączenie tych pozycji uzupełniło tło teoretyczne o prace pionierskie z początkowego okresu rozwoju agentów opartych na LLM.

Wstępna ekstrakcja danych (1/2)

Artykuł	Słowa kluczowe	Model	Środowisko
[1] — <i>Mendikot</i>	Prompt engineering, game theory	GPT-4o	Mendikot (gra karciana)
Inżynieria promptów (uczenie na wzorcach eksperckich, dynamiczna modyfikacja) podniosła win-rate z 45% do 65% w środowisku o niepełnej informacji.			
[2] — <i>Strategic Behavior</i>	Strategic behavior, game structure, framing	GPT-4, LLaMA-2-70B	Dylemat więźnia, Stag Hunt
GPT-4 reaguje silniej na zmianę struktury wypłat; LLaMA-2-70B — na narracyjny kontekst. Sposób przekazania reguł radykalnie wpływa na jakość decyzji.			
[3] — <i>StarCraft II</i>	Real-time policy, adaptive control	GPT-4, Claude 2, Gemini Pro	StarCraft II
Możliwa dynamiczna korekta strategii w czasie rzeczywistym bez ponownego trenowania. LLM adaptują się do zmian stanu gry.			

Artykuł	Słowa kluczowe	Model	Środowisko
[8] — <i>Linguistic Constraints</i>	Context window, Nash equilibrium, bounded memory	GPT-4o, LLaMA-3-70B, Mistral-7B	Linguistic Uncertainty Game
Wykazano istnienie progu (~4096 tokenów), poniżej którego skuteczność modeli znacząco spada, oraz wyróżniono trzy tryby działania. Wyniki są istotne dla naszego projektu, bo długie instrukcje gier mogą przekraczać efektywny zakres przetwarzania.			
[15] — <i>Complex Systems</i>	Complex systems, game theory, social dynamics	GPT-3.5-turbo, GPT-4, LLaMA-2	Dylemat więźnia, sieci złożone
LLM kooperują częściej niż ludzie (65,4% vs 37%), ale GPT-4 w grach iterowanych stosuje <i>unforgiving tit-for-tat</i> — po jednej zdradzie trwale przechodzi na rywalizację.			
[16] — <i>Randomness & Strategy</i>	Game theory, stochasticity, loss aversion	GPT-4o-mini	Kamień-Papier-Nożyce, Dylemat więźnia
LLM nie są losowe — silne uprzedzenia przy generowaniu wyborów, awersja do straty, zbieganie do patowej powtarzalności w RPS. Potrzeba zewnętrznego generatora losowości.			

Wnioski

Przebieg i wyzwania:

- Największe wyzwanie: odfiltrowanie wyników niezwiązanych z grami (np. medycyna, energetyka).
- Zotero znacząco usprawniło zarządzanie bibliografią i deduplikację.
- 147 unikalnych pozycji → 6 artykułów do pełnej ekstrakcji danych.

Kluczowe obserwacje:

- Hipoteza potwierdzona: LLMy (GPT-4+) wykazują zdolność adaptacji do gier.
- Techniki: Inżynieria promptów i Chain-of-Thought są niezbędne do poziomu eksperckiego.
- Zachowania: Modele mogą tworzyć nowe zasady lub próbować oszukiwać graczy.

Prompt jest dominującym czynnikiem skuteczności

- [1]: ten sam GPT-4o, prompt → win-rate z **45% do 65%**
- [2]: zmiana opisu reguł (framing) → diametralnie różne decyzje
- [8]: próg 4096 tokenów — poniżej niego skuteczność dramatycznie spada

Dla projektu: nie wystarczy wybrać „najlepszy model”, — kluczowe jest *jak* i *ile* informacji prześlemy agentowi.

Wniosek 2: Systematyczne uprzedzenia

LLM nie zachowują się jak racjonalni gracze

- [16]: awersja do straty, niemożność generowania losowych wyborów w RPS
- [15]: nadmierna kooperatywność (65,4% vs 37% u ludzi), ale *unforgiving tit-for-tat* po zdradzie

Uprzedzenia są **systematyczne**, lecz różnią się kontekstem gry.

Dla projektu: kalibracja agenta pod konkretną mechanikę gry (losowość vs. kooperacja).

Wniosek 3: Paradoks złożoności

Złożoność pomaga, prostota szkodzi

Złożone środowisko:

StarCraft II [3]

→ skuteczna adaptacja w czasie rzeczywistym

Proste środowisko:

Kamień-Papier-Nożyce [16]

→ patowa powtarzalność

Wyjaśnienie: złożone gry dostarczają bogatszego kontekstu tekstowego; proste gry wymagają prawdziwej losowości, której LLM nie posiada.

Dla projektu: zaczynać od gier o bogatej mechanice, nie od prostych.

Wniosek 4: Wybór modelu ma znaczenie

Modele różnią się jakościowo, nie tylko ilościowo

- [2]: GPT-4 reaguje na strukturę wypłat; LLaMA-2-70B na narrację
- [15]: GPT-4 „nie wybacza„ zdrady; GPT-3.5 jest skłonny do przebaczenia

Dla projektu: wybór modelu powinien być świadomą decyzją powiązaną z typem gry — model wrażliwy na narrację vs. model wrażliwy na strukturę reguł.

1. **Projekt promptu ważniejszy niż wybór modelu** — iteracyjne testowanie sposobu przekazania reguł gry (styl, kolejność, szczegółowość).
2. **Zarządzanie budżetem kontekstu** — instrukcje gier powinny mieścić się powyżej progu 4096 tokenów efektywnego przetwarzania strategicznego.
3. **Zewnętrzna losowość i kalibracja** — agent powinien korzystać z zewnętrznego generatora losowości w grach z elementem losowym.
4. **Zaczynać od gier o bogatej mechanice** — złożone gry planszowe mogą paradoksalnie być łatwiejsze dla agenta LLM niż proste.

Dziękujemy za uwagę!

- [1] A. J. -, „Optimizing LLM Strategies for Playing Mendikot using Prompt Engineering”, *IJFMR*, t. 6, nr 6, s. 30130, lis. 2024, doi: 10.36948/ijfmr.2024.v06i06.30130.
- [2] N. Lorè i B. Heydari, „Strategic behavior of large language models and the role of game structure versus contextual framing”, *Sci Rep*, t. 14, nr 1, s. 18490, sie. 2024, doi: 10.1038/s41598-024-69032-z.
- [3] W. Ma, D. Xu, S. Lin, H. Zhang, i J. Wang, „Adaptive Command : Real-Time Policy Adjustment via Language Models in StarCraft II”, w *Proceedings of the 2024 Sixth International Conference on Distributed Artificial Intelligences*, Singapore Singapore: ACM, grud. 2024, s. 22–30. doi: 10.1145/3719545.3721029.
- [4] K. Horibe, „Evolvability in Rule-Making: A Self-Amendment Game Among LLM Agents”, w *Proceedings of the Genetic and Evolutionary Computation Conference Companion*, NH Malaga Hotel Malaga Spain: ACM, lip. 2025, s. 2127–2137. doi: 10.1145/3712255.3734367.

- [5] R. Hadfi i Y. J. Huang, „Personality-Aware Multiagent Large Language Models for Strategic Interactions in Polymatrix Games”, w *Proceedings of the 13th International Conference on Human-Agent Interaction*, Yokohama Japan: ACM, lis. 2025, s. 521–523. doi: 10.1145/3765766.3765856.
- [6] K. Poje, M. Brcic, M. Kovac, i M. B. Babac, „Effect of Private Deliberation: Deception of Large Language Models in Game Play”, *Entropy*, t. 26, nr 6, s. 524, cze. 2024, doi: 10.3390/e26060524.
- [7] A. Stepin *et al.*, „B3Emo: Quantifying Affect as a Double-Edged Sword in Strategic LLM Interactions”, *IEEE Access*, s. 1, 2026, doi: 10.1109/ACCESS.2026.3673221.
- [8] S. Yoon, „Strategic Learning Under Linguistic and Contextual Constraints: A Theoretical Framework for LLM-Based Multi-Agent Coordination”, *IEEE Access*, t. 13, s. 197053–197071, 2025, doi: 10.1109/ACCESS.2025.3628927.

- [9] J. De Curtò i I. De Zarzà, „LLM-Driven Social Influence for Cooperative Behavior in Multi-Agent Systems”, *IEEE Access*, t. 13, s. 44330–44342, 2025, doi: 10.1109/ACCESS.2025.3548451.
- [10] Y. Wang, Y. Wang, F. Tian, J. Ma, i Q. Jin, „Intelligent games meeting with multi-agent deep reinforcement learning: a comprehensive review”, *Artif Intell Rev*, t. 58, nr 6, s. 165, mar. 2025, doi: 10.1007/s10462-025-11166-1.
- [11] A. Hintze i C. Adami, „Promoting cooperation in the public goods game using artificial intelligent agents”, *npj Complex*, t. 3, nr 1, s. 3, sty. 2026, doi: 10.1038/s44260-025-00065-9.
- [12] O. Macmillan-Scott i M. Musolesi, „(Ir)rationality in AI: state of the art, research challenges and open questions”, *Artif Intell Rev*, t. 58, nr 11, s. 352, sie. 2025, doi: 10.1007/s10462-025-11341-4.

- K. Fujii, „Predictive Analysis and Play Evaluation with Machine Learning”, *Machine Learning in Sports*. Springer Nature Singapore, Singapore, s. 59–84, 2025. doi: 10.1007/978-981-96-1445-5_3.
- [13]
- A. Mouri Zadeh Khaki i A. Choi, „Evaluating Fairness in LLM Negotiator Agents via Economic Games Using Multi-Agent Systems”, *Mathematics*, t. 14, nr 3, s. 458, sty. 2026, doi: 10.3390/math14030458.
- [14]
- Y. Lu, A. Aleta, C. Du, L. Shi, i Y. Moreno, „LLMs and generative agent-based models for complex systems research”, *Physics of Life Reviews*, t. 51, s. 283–293, grud. 2024, doi: 10.1016/j.plrev.2024.10.013.
- [15]
- A. Vidler i T. Walsh, „Playing games with Large language models: Randomness and strategy”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2503.02582>
- [16]

- S. Mao *et al.*, „ALYMPICS: LLM Agents Meet Game Theory – Exploring Strategic Decision-Making with AI Agents”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2311.03220>
- [17]
- N. Lorè i B. Heydari, „Strategic Behavior of Large Language Models: Game Structure vs. Contextual Framing”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2309.05898>
- [18]
- I. De Zarzà, J. De Curtò, G. Roig, P. Manzoni, i C. T. Calafate, „Emergent Cooperation and Strategy Adaptation in Multi-Agent Systems: An Extended Coevolutionary Theory with LLMs”, *Electronics*, t. 12, nr 12, s. 2722, cze. 2023, doi: 10.3390/electronics12122722.
- [19]