

Systematic Literature Review Report

Modele LLM jako uniwersalne agenty adaptujące się do systemów złożonych na przykładzie gier planszowych

Supervisor: dr inż. Krzysztof Manuszewski

Krzysztof Nasuta 193328

Bartłomiej Krawisz 193319

Filip Dawidowski 193433

Stanisław Nieradko 193044

Table of Contents

1. Research project	3
1.1. Title	3
1.2. Supervisor	3
1.3. Goals and short description	3
2. Systematic Literature Review plan	3
2.1. Goals and questions	3
2.2. Keywords	3
2.3. Search strings	4
2.4. Literature databases	4
2.5. Inclusion criteria	4
2.6. Exclusion criteria	4
2.7. Quality criteria	5
2.8. Data extraction	5
2.9. SLR process	5
3. Systematic Literature Review results	6
3.1. Results in numbers	6
3.2. Articles selected for data extraction	6
3.3. Snowballed articles	7
3.4. Article statistics	7
3.5. Initial extracted data	8
4. Conclusions	9
4.1. SLR process	9
4.2. SLR results	9
4.2.1. Prompt jest dominującym czynnikiem skuteczności	9
4.2.2. LLM wykazują systematyczne uprzedzenia behawioralne	9
4.2.3. Paradoks adaptacji: złożoność pomaga, prostota szkodzi	10
4.2.4. Wybór modelu nie jest obojętny	10
4.2.5. Implikacje dla projektu	10
5. Literature	10

1. Research project

1.1. Title

Modele LLM jako uniwersalne agenty adaptujące się do systemów złożonych na przykładzie gier planszowych

1.2. Supervisor

dr inż. Krzysztof Manuszewski

1.3. Goals and short description

Celem pracy jest opracowanie agenta wykorzystującego duże modele językowe (LLM), zdolnego do prowadzenia rozgrywki w gry planszowe wyłącznie na podstawie analizy ich instrukcji.

Projekt powinien pozwalać na symulację zachowania żywego gracza w złożonych, dynamicznych systemach decyzyjnych. Rozwiązanie musi umożliwiać skuteczną interakcję na linii agent-środowisko poprzez czytelną reprezentację bieżącego stanu gry, rejestrowanie ruchów przeciwników oraz komunikowanie własnych posunięć. Projekt zakłada podejście iteracyjne, z początkowym ograniczeniem testów do gier o prostszej mechanice (np. niewymagających analizy przestrzennego położenia komponentów na planszy).

Hipotezą badawczą jest weryfikacja możliwości skutecznego adaptowania się agenta LLM do reguł gry oraz podejmowania trafnych decyzji na podstawie znajomości samej instrukcji tekstowej.

2. Systematic Literature Review plan

2.1. Goals and questions

- Zidentyfikowanie i analiza istniejących badań dotyczących wykorzystania Large Language Models jako agentów decyzyjnych w systemach złożonych, szczególnie w środowiskach gier.
- Identyfikacja technik oceny skuteczności agentów LLM w zadaniach strategicznych.
- Zapoznanie się z istniejącymi sposobami przekazywania do agenta AI informacji o systemie złożonym.
- Zidentyfikowanie ograniczeń, wyzwań oraz luk badawczych w wykorzystaniu LLM jako uniwersalnych agentów w systemach złożonych.

2.2. Keywords

- **Związane z LLM:** *large language model, large language models, LLM, foundation models, language model agents, transformer models*
- **Agenci i podejmowanie decyzji:** *LLM agents, autonomous agents, AI agents, agent-based systems, decision making, planning, reasoning, tool-augmented LLM, LLM-based agents, artificial intelligence*
- **Adaptacja i systemy złożone:** *complex systems, adaptive systems, multi-agent systems, dynamic environments, environment interaction, strategic decision making*
- **Gry strategiczne lub planszowe:** *board games, game environments, strategic games, game-playing agents, AI in games, game AI, game theory*

2.3. Search strings

("large language model" OR "large language models" OR "LLM" OR "foundation models" OR "language model agents" OR "transformer models")

AND

("LLM agents" OR "autonomous agents" OR "AI agents" OR "agent-based systems" OR "decision making" OR "planning" OR "reasoning" OR "tool-augmented LLM" OR "LLM-based agents" OR "artificial intelligence")

AND

("complex systems" OR "adaptive systems" OR "multi-agent systems" OR "dynamic environments" OR "environment interaction" OR "strategic decision making")

AND

("board games" OR "game environments" OR "strategic games" OR "game-playing agents" OR "AI in games" OR "game AI" OR "game theory")

Program 1: Logiczna struktura zapytania wyszukiwania (Search String)

("large language model" OR "large language models" OR "LLM" OR "foundation models" OR "language model agents" OR "transformer models")

AND

("LLM agents" OR "autonomous agents" OR "AI agents" OR "agent-based systems" OR "decision making" OR "planning" OR "reasoning" OR "tool-augmented LLM" OR "LLM-based agents" OR "artificial intelligence")

AND

("complex systems" OR "adaptive systems" OR "multi-agent systems" OR "dynamic environments" OR "environment interaction" OR "strategic decision making")

AND

("board games" OR "game environments" OR "strategic games" OR "game-playing agents" OR "AI in games" OR "game AI" OR "game theory")

2.4. Literature databases

- **Katalog BPG** – główna wyszukiwarka zasobów Biblioteki Politechniki Gdańskiej, zapewniająca dostęp do lokalnych książek oraz subskrybowanych baz artykułów naukowych.
- **IEEEExplore** – wiodąca baza cyfrowa zawierająca publikacje z zakresu informatyki i nowych technologii, kluczowa w poszukiwaniu najnowszych badań nad sztuczną inteligencją i modelami językowymi.
- **SpringerLink** – obszerna platforma wydawnicza oferująca dostęp do recenzowanych czasopism i materiałów konferencyjnych, przydatna do poszerzonego przeglądu literatury z dziedziny systemów złożonych.

2.5. Inclusion criteria

Lata publikacji: od 2024

Języki: angielski albo polski

2.6. Exclusion criteria

Publikacje, które nie są dostępne w ramach otwartego dostępu (*Open Access*), podlegają odrzuceniu na początkowym etapie selekcji.

2.7. Quality criteria

QA_S	Quality Assessment Criteria (QA)
QA_1	Is the paper based on empirical research regarding LLM agents (rather than purely theoretical discussion)?
QA_2	Is there a clear statement of the aims regarding the LLM's adaptation to complex systems or games?
QA_3	Is there an adequate description of the game environment or complex system used for testing?
QA_4	Was the agent architecture and prompting strategy appropriate to address the aims of the research?
QA_5	Was the evaluation method (e.g., win rate, rule adherence) appropriate for assessing the agent's performance?
QA_6	Was there a clear baseline (e.g., traditional AI, heuristic bot, human player) with which to compare the LLM?
QA_7	Was the data regarding the LLM's decision-making and reasoning process collected in a rigorous way?
QA_8	Was the analysis of the agent's behavior and performance sufficiently rigorous?
QA_9	Have the limitations of the LLM (e.g., context window limits, hallucinations, API costs) been considered to an adequate degree?
QA_{10}	Is there a clear statement of findings regarding the LLM's ability to play or adapt based on textual instructions?
QA_{11}	Is the study of value for developing autonomous LLM agents for strategic board games?

Response Scale				
Excellent	Very Good	Good	Fair	Poor
4	3	2	1	0

2.8. Data extraction

Dla każdego artykułu zweryfikowano następujące aspekty: jaki był jego cel, co zostało w nim osiągnięte i jakie problemy zostały napotkane w trakcie badań.

Na podstawie pozyskanych danych utworzony został arkusz z informacjami:

- Nazwa artykułu
- Słowa kluczowe
- Typ wykorzystanego agenta
- Rodzaj badanego systemu
- Główne wnioski

2.9. SLR process

1. Planowanie
 - Wszyscy członkowie wspólnie ustalili pytania oraz cele ekstrakcji.
2. Wybór baz artykułów
 - Wybrane zostały *Katalog BPG*, *IEEEExplore* oraz *SpringerLink*
3. Doprecyzowanie zapytań wyszukiwawczych

4. Walidacja i dostosowanie kryteriów włączenia
5. Surowe wyniki wyszukiwania
 - Z wybranych baz pobrane zostały wyniki wyszukiwania w ilościach podanych w sekcji 3.1
6. Usuwanie duplikatów
 - Zastosowany został program **Zotero**
7. Selekcja na podstawie tytułu i streszczenia artykułu
 - Zastosowany został program **Zotero**
8. Selekcja na podstawie pełnego tekstu
 - Artykuły zostały rozdzielone pomiędzy członków zespołu do szczegółowej lektury. Każda pozycja została zweryfikowana pod kątem merytorycznej zgodności z pytaniami badawczymi oraz spełnienia kryteriów jakości (QA). Każdy wybrany artykuł był dodatkowo weryfikowany przez innego członka zespołu.
9. Snowballing
 - Przeprowadzono metodę **backward snowballing**, polegającą na analizie bibliografii wybranych artykułów w celu zidentyfikowania bazowych prac pominiętych w automatycznym wyszukiwaniu z powodu przyjętych kryteriów.
10. Ekstrakcja danych badawczych i synteza
 - Z każdego zaakceptowanego artykułu wydobyto kluczowe informacje: cele badania, wykorzystane modele LLM, rodzaje gier/systemów oraz główne wnioski dotyczące skuteczności agentów. Dane te zostały ujednolicone i zestawione w tabelach, co pozwoliło na przeprowadzenie syntezy jakościowej i wyciągnięcie wniosków dotyczących aktualnego stanu wiedzy.
11. Raportowanie

3. Systematic Literature Review results

3.1. Results in numbers

Baza danych	Znalezione pozycje	Po usunięciu duplikatów	Po selekcji (Screening)	Po przeczytaniu (Full-text)
IEEEExplore	3	3	3	2
Katalog BPG	47	45 (2)	12	6
SpringerLink	99	99	20	8
Suma	149	147 (2)	35	16

Tabela 1: Zestawienie liczbowe artykułów na poszczególnych etapach procesu SLR z podziałem na bazy danych

3.2. Articles selected for data extraction

Na podstawie kryteriów włączenia, wykluczenia oraz oceny jakości (QA), do pełnej lektury i analizy wybrano 16 artykułów:

- [1] – Optymalizacja strategii LLM w grze Mendikot przy użyciu inżynierii promptów.
- [2] – Badanie zachowań strategicznych LLM i roli struktury gry vs. kontekstu.
- [3] – Adaptacyjne sterowanie i korekta polityki w czasie rzeczywistym w StarCraft II.
- [4] – Ewolucyjność w tworzeniu reguł w grach między agentami LLM.
- [5] – Wielozadaniowe modele LLM uwzględniające osobowość w interakcjach strategicznych.
- [6] – Wpływ prywatnej deliberacji na skłonność do oszustw w rozgrywkach LLM.
- [7] – Kwantyfikacja afektu jako obosiecznego miecza w strategicznych interakcjach LLM.

- [8] – Strategiczne uczenie się pod ograniczeniami lingwistycznymi i kontekstowymi.
- [9] – Wpływ społeczny sterowany przez LLM na zachowania kooperacyjne.
- [10] – Przegląd inteligentnych gier i głębokiego wzmocnionego uczenia wieloagentowego.
- [11] – Promowanie kooperacji w grach o dobra publiczne przy użyciu agentów AI.
- [12] – (Ir)racjonalność w AI: stan wiedzy i otwarte pytania badawcze.
- [13] – Predykccyjna analiza i ewaluacja rozgrywki z wykorzystaniem uczenia maszynowego.
- [14] – Ewaluacja sprawiedliwości agentów negocjacyjnych LLM w grach ekonomicznych.
- [15] – LLM i generatywne modele agentowe w badaniach nad systemami złożonymi.
- [16] – Losowość i strategia w grach LLM: awersja do straty i uprzedzenia stochastyczne.

3.3. Snowballed articles

Zgodnie z metodologią przedstawioną na wykładzie, przeprowadzono przegląd list referencyjnych w artykułach zaakceptowanych do końcowej analizy. Celem było zidentyfikowanie najczęściej cytowanych pozycji, które nie zostały odnalezione w pierwotnym procesie wyszukiwania (np. ze względu na bycie starszymi niż założony próg lat lub specyficzne słowa kluczowe).


W wyniku tej analizy zidentyfikowano 3 kluczowe publikacje z 2023 roku, które stanowią fundament dla nowszych badań nad agentami LLM:

- [17] – Praca wprowadzająca platformę ALYMPICS, często cytowana jako jeden z pierwszych testów strategicznych dla agentów LLM.
- [18] – Wcześniejsza wersja badań nad wpływem struktury gry na zachowanie modeli, stanowiąca punkt odniesienia dla późniejszych eksperymentów.
- [19] – Artykuł teoretyczny dotyczący kooperacji emergentnej, na który powołują się autorzy prac z lat 2024–2025 analizujący dynamikę wieloagentową.

Włączenie tych pozycji pozwoliło na uzupełnienie tła teoretycznego o prace pionierskie z początkowego okresu rozwoju agentów opartych na dużych modelach językowych.

3.4. Article statistics

Większość przeanalizowanych artykułów pochodzi z lat 2024–2025, co odzwierciedla dynamiczny rozwój dziedziny agentów LLM w ostatnim czasie. Rozkład roczny wszystkich znalezionych unikalnych pozycji (147) przedstawiono na poniższym wykresie:



Rysunek 1: Rozkład publikacji w czasie dla zidentyfikowanych artykułów (stan na marzec 2026)

Głównym tematem publikacji jest kooperacja w systemach wieloagentowych (MAS), ewaluacja zdolności strategicznych oraz inżynieria promptów dla złożonych procesów decyzyjnych.

3.5. Initial extracted data

Poniższa tabela przedstawia dane wyekstrahowane z wybranych artykułów. Dla każdego artykułu wiersz z głównymi wnioskami obejmuje pełną szerokość tabeli.

Artykuł	Główne słowa kluczowe	Model LLM	Środowisko / Gra
[1] — <i>Optimizing LLM Strategies for Playing Mendikot using Prompt Engineering</i>	Prompt engineering, game theory	GPT-4o	Mendikot (gra karciana)
Przedmiotem artykułu była optymalizacja strategii modelu GPT-4o w tradycyjnej indyjskiej grze karcianej Mendikot przy użyciu zaawansowanej inżynierii promptów. Badanie wykazało, że zastosowanie technik takich jak uczenie na wzorcach eksperckich i dynamiczna modyfikacja promptów pozwoliło podnieść odsetek wygranych z 45% do 65%, co stanowi istotny wzrost w środowisku o niepełnej informacji. Wynik ten sugeruje, że odpowiednio zaprojektowane prompty mogą skutecznie zastępować tradycyjne metody treningu w grach karcianych, co jest bezpośrednio obiecujące dla naszego projektu dotyczącego adaptacji agenta LLM do gier planszowych wyłącznie na podstawie instrukcji tekstowej.			
[2] — <i>Strategic Behavior of Large Language Models and the Role of Game Structure versus Contextual Framing</i>	Strategic behavior, game structure, framing	GPT-4, LLaMA-2-70B	Dylemat więźnia, Stag Hunt
Przedmiotem artykułu było zbadanie, w jakim stopniu zachowania strategiczne modeli LLM zależą od struktury matematycznej gry w porównaniu z jej opisem słownym (tzw. framing). Badanie wykazało istotne różnice między modelami — GPT-4 reagował silniej na zmianę struktury wypłat, natomiast LLaMA-2-70B był bardziej podatny na kontekstowe sformułowanie scenariusza, co wskazuje na fundamentalną rozbieżność w sposobie przetwarzania informacji strategicznej. Odkrycie to ma kluczowe znaczenie dla projektowania agentów do gier planszowych, ponieważ sugeruje, że sam sposób przekazania reguł (np. styl instrukcji) może radykalnie wpłynąć na jakość podejmowanych decyzji.			
[3] — <i>Adaptive Command: Real-Time Policy Adjustment via Language Models in StarCraft II</i>	Real-time policy, adaptive control	GPT-4, Claude 2, Gemini Pro	StarCraft II
Przedmiotem artykułu była analiza poziomu gry różnych agentów LLM w strategię czasu rzeczywistego StarCraft II. Badanie wykazało, że modele umożliwiają korektę strategii w czasie rzeczywistym w środowiskach o wysokiej złożoności, dynamicznie dostosowując politykę działania na podstawie zmieniającego się stanu gry bez konieczności ponownego trenowania. Daje to nadzieję na dobre radzenie sobie modeli także w badanych przez nas grach planszowych, gdzie agent musi adaptować się do ruchów przeciwnika i zmieniającego się stanu rozgrywki w oparciu o sam opis reguł.			
[8] — <i>Strategic Learning Under Linguistic and Contextual Constraints: A Theoretical Framework for LLM-Based Multi-Agent Coordination</i>	Context window, Nash equilibrium, bounded memory, phase transitions	GPT-4o, GPT-4-turbo, LLaMA-3-70B, Mistral-7B	Linguistic Uncertainty Game (LUG)
Przedmiotem artykułu było opracowanie formalnego modelu matematycznego (Context-Constrained Nash Equilibrium) opisującego ograniczenia okna kontekstowego LLM w uczeniu się strategicznym. Badanie wykazało istnienie przejść fazowych przy 4096 tokenach kontekstu — poniżej tego progu skuteczność agenta dramatycznie spada — oraz zidentyfikowało trzy reżimy operacyjne: ograniczony pamięcią, ograniczony kontekstem i nieograniczony, osiągając 18,7% poprawę wydajności. Wyniki te mają bezpośrednie przełożenie na nasz projekt, ponieważ obszerne instrukcje gier planszowych mogą przekraczać próg efektywnego przetwarzania informacji strategicznej.			
[15] — <i>LLMs and Generative Agent-Based Models for Complex Systems Research</i>	Complex systems, game theory, social dynamics, agent-based models	GPT-3.5-turbo, GPT-4, LLaMA-2	Dylemat więźnia, sieci złożone, dynamika społeczna
Przedmiotem artykułu był obszerny przegląd zastosowań LLM i generatywnych modeli agentowych (GABM) w badaniach nad systemami złożonymi, obejmujący sieci złożone, teorię gier, dynamikę społeczną i modelowanie epidemii. Kluczowe odkrycie dotyczy kooperatywności — LLM są bardziej skłonne do współpracy niż ludzie w Dylemacie Więźnia (65,4% vs 37%), lecz GPT-4 w wariancie iterowanym stosował strategię <i>unforgiving tit-for-tat</i> — po jednej zdradzie przeciwnika trwale przechodził na rywalizację. Praca kompleksowo opisuje, w jaki sposób LLM reprodukuja ludzkie wzorce zachowań			

Artykuł	Główne słowa kluczowe	Model LLM	Środowisko / Gra
— sprawiedliwość, kooperację, przestrzeganie norm — ale z istotnymi ograniczeniami (wrażliwość na prompt, halucynacje), które muszą być uwzględnione przy projektowaniu agenta do gier planszowych.			
[16] — <i>Playing Games with Large Language Models: Randomness and Strategy</i>	Game theory, stochasticity, loss aversion	GPT-4o-mini	Kamień-Papier-Nożyce, Dylemat więźnia
Przedmiotem artykułu było przetestowanie zdolności modelu GPT-4o-mini do gry w dwie klasyczne gry: Kamień-Papier-Nożyce (RPS) i Dylemat Więźnia (PD). Badanie wykazało, że LLM „nie są zbyt stochastyczne,” — model wykazywał silne uprzedzenia w generowaniu rzekomo losowych wyborów, rozwijał strategię unikania przegranej (loss aversion), a w RPS rozgrywki szybko zbiegały do patowej powtarzalności. Wyniki wskazują na fundamentalne ograniczenie LLM w grach wymagających losowości — agent grający w gry planszowe z elementem losowym może potrzebować zewnętrznego generatora losowości zamiast polegać na „losowych” wyborach modelu.			

Tabela 2: Ekstrakcja danych z wybranych pozycji literaturowych

4. Conclusions

4.1. SLR process

Proces SLR przebiegł zgodnie z założonym planem. Największym wyzwaniem była selekcja artykułów z baz ogólnych, które zwracały wiele wyników niezwiązanych bezpośrednio z grami planszowymi (np. gry wojenne w medycynie czy energetyce). Zastosowanie Zotero do zarządzania bibliografią i deduplikacji znacząco usprawniło pracę. W sumie przeanalizowano 147 unikalnych pozycji, z których do końcowej ekstrakcji danych wybrano 6 artykułów najbardziej powiązanych z hipotezą badawczą.

4.2. SLR results

Zestawienie danych z sześciu przeanalizowanych artykułów ujawnia kilka przekrojowych prawidłowości dotyczących agentów LLM w środowiskach gier.

4.2.1. Prompt jest dominującym czynnikiem skuteczności

Trzy niezależne badania wskazują spójnie, że sposób konstrukcji promptu ma większy wpływ na jakość gry agenta niż sam wybór modelu. W grze Mendikot [1] zastosowanie inżynierii promptów podniosło win-rate z 45% do 65% — przy tym samym modelu GPT-4o. Jednocześnie [2] wykazali, że zmiana sformułowania reguł (framing) przy niezminionej strukturze wypłat prowadzi do diametralnie różnych decyzji strategicznych. Te obserwacje łączy trzeci wynik — [8] zidentyfikował próg 4096 tokenów kontekstu, poniżej którego skuteczność agenta gwałtownie spada. Razem oznacza to, że w naszym projekcie nie wystarczy wybrać „najlepszy model,” — kluczowe będzie, *jak* i *ile* informacji o grze planszowej prześlemy agentowi w prompcie.

4.2.2. LLM wykazują systematyczne uprzedzenia behawioralne

Dane z tabeli ujawniają, że agenci LLM nie zachowują się jak racjonalni gracze — mają powtarzalne, przewidywalne odchylenia od optymalnej strategii. [16] wykazał silną awersję do straty (loss aversion) i niezdolność do generowania losowych wyborów w RPS. [15] z kolei udokumentował nadmierną kooperatywność LLM w Dylemacie Więźnia (65,4% vs 37% u ludzi), ale jednocześnie GPT-4 w wariacie iterowanym (wielorundowym) stosował strategię *unforgiving tit-for-tat* — po jednej zdradzie przeciwnika trwale przechodził na strategię rywalizacyjną, nie wracając już do kooperacji. Zestawienie tych wyników pokazuje, że uprzedzenia LLM są systematyczne, ale różnią się w zależności od kontekstu gry — agent w grze planszowej będzie więc wymagał kalibracji pod kątem konkretnej mechaniki (np. czy gra wymaga losowości, czy kooperacji).

4.2.3. Paradoks adaptacji: złożoność pomaga, prostota szkodzi

Zaskakującym wnioskiem z porównania danych jest to, że LLM radzą sobie *lepiej* w złożonych środowiskach niż w prostych. W StarCraft II [3] agenty skutecznie adaptowały strategię w czasie rzeczywistym, dynamicznie reagując na zmiany stanu gry. Tymczasem w elementarnym Kamień-Papier-Nożyce [16] model zbiegał do patowej powtarzalności i nie potrafił przełamać schematów. Wyjaśnieniem może być fakt, że złożone gry dostarczają bogatszego kontekstu tekstowego, na którym LLM operuje naturalnie, natomiast gry wymagające czystej losowości lub prostej heurystyki obnażają fundamentalne ograniczenie modelu — brak prawdziwej stochastyczności. Dla naszego projektu oznacza to, że gry planszowe o bogatszej mechanice (wiele reguł, interakcje między komponentami) mogą paradoksalnie być łatwiejsze dla agenta niż gry o prostych, ale losowych rozstrzygnięciach.

4.2.4. Wybór modelu nie jest obojętny

Choć prompt dominuje, dane z tabeli pokazują też, że modele różnią się między sobą w sposób jakościowy, a nie tylko ilościowy. [2] wykazał, że GPT-4 i LLaMA-2-70B reagują na *inne* aspekty gry — GPT-4 na strukturę wypłat, LLaMA-2 na narracyjny kontekst. [15] z kolei pokazał, że GPT-4 w grach iterowanych trwale karze zdradę (jak opisano powyżej), podczas gdy GPT-3.5 jest skłonny do „przebaczenia,” — mimo że oba modele są kooperatywne w wariancie jednorazowym. Oznacza to, że w naszym projekcie wybór modelu powinien być świadomą decyzją powiązaną z typem gry planszowej — model wrażliwy na narrację może lepiej radzić sobie z grami o tematycznych instrukcjach, a model wrażliwy na strukturę — z grami o ścisłych regułach.

4.2.5. Implikacje dla projektu

Z powyższej syntezy wynikają cztery konkretne rekomendacje:

1. **Projekt promptu ważniejszy niż wybór modelu** — nakład pracy powinien iść przede wszystkim w iteracyjne testowanie sposobu przekazania reguł gry (styl, kolejność, szczegółowość), a nie w porównywanie kolejnych modeli [1], [2].
2. **Zarządzanie budżetem kontekstu** — instrukcje gier planszowych powinny być kompresowane lub segmentowane tak, aby zmieścić się powyżej progu 4096 tokenów efektywnego przetwarzania strategicznego [8].
3. **Zewnętrzna losowość i kalibracja** — agent powinien korzystać z zewnętrznego generatora losowości w grach z elementem losowym, a jego tendencje behawioralne (np. nadmierna kooperacja, loss aversion) powinny być testowane i korygowane na etapie ewaluacji [15], [16].
4. **Zaczynać od gier o bogatej mechanice** — wbrew intuicji, złożone gry planszowe z rozbudowanymi regułami mogą dawać agentowi LLM więcej kontekstu do pracy niż gry proste, co jest spójne z obserwowanym paradoksem adaptacji [3], [16].

5. Literature

- [1] A. J. -, „Optimizing LLM Strategies for Playing Mendikot using Prompt Engineering”, *IJFMR*, t. 6, nr 6, s. 30130, lis. 2024, doi: 10.36948/ijfmr.2024.v06i06.30130.
- [2] N. Lorè i B. Heydari, „Strategic behavior of large language models and the role of game structure versus contextual framing”, *Sci Rep*, t. 14, nr 1, s. 18490, sie. 2024, doi: 10.1038/s41598-024-69032-z.
- [3] W. Ma, D. Xu, S. Lin, H. Zhang, i J. Wang, „Adaptive Command : Real-Time Policy Adjustment via Language Models in StarCraft II”, w *Proceedings of the 2024 Sixth Inter-*

- national Conference on Distributed Artificial Intelligences*, Singapore Singapore: ACM, grud. 2024, s. 22–30. doi: 10.1145/3719545.3721029.
- [4] K. Horibe, „Evolvability in Rule-Making: A Self-Amendment Game Among LLM Agents”, w *Proceedings of the Genetic and Evolutionary Computation Conference Companion*, NH Malaga Hotel Malaga Spain: ACM, lip. 2025, s. 2127–2137. doi: 10.1145/3712255.3734367.
 - [5] R. Hadfi i Y. J. Huang, „Personality-Aware Multiagent Large Language Models for Strategic Interactions in Polymatrix Games”, w *Proceedings of the 13th International Conference on Human-Agent Interaction*, Yokohama Japan: ACM, lis. 2025, s. 521–523. doi: 10.1145/3765766.3765856.
 - [6] K. Poje, M. Brcic, M. Kovac, i M. B. Babac, „Effect of Private Deliberation: Deception of Large Language Models in Game Play”, *Entropy*, t. 26, nr 6, s. 524, cze. 2024, doi: 10.3390/e26060524.
 - [7] A. Stepin *et al.*, „B3Emo: Quantifying Affect as a Double-Edged Sword in Strategic LLM Interactions”, *IEEE Access*, s. 1, 2026, doi: 10.1109/ACCESS.2026.3673221.
 - [8] S. Yoon, „Strategic Learning Under Linguistic and Contextual Constraints: A Theoretical Framework for LLM-Based Multi-Agent Coordination”, *IEEE Access*, t. 13, s. 197053–197071, 2025, doi: 10.1109/ACCESS.2025.3628927.
 - [9] J. De Curtò i I. De Zarzà, „LLM-Driven Social Influence for Cooperative Behavior in Multi-Agent Systems”, *IEEE Access*, t. 13, s. 44330–44342, 2025, doi: 10.1109/ACCESS.2025.3548451.
 - [10] Y. Wang, Y. Wang, F. Tian, J. Ma, i Q. Jin, „Intelligent games meeting with multi-agent deep reinforcement learning: a comprehensive review”, *Artif Intell Rev*, t. 58, nr 6, s. 165, mar. 2025, doi: 10.1007/s10462-025-11166-1.
 - [11] A. Hintze i C. Adami, „Promoting cooperation in the public goods game using artificial intelligent agents”, *npj Complex*, t. 3, nr 1, s. 3, sty. 2026, doi: 10.1038/s44260-025-00065-9.
 - [12] O. Macmillan-Scott i M. Musolesi, „(Ir)rationality in AI: state of the art, research challenges and open questions”, *Artif Intell Rev*, t. 58, nr 11, s. 352, sie. 2025, doi: 10.1007/s10462-025-11341-4.
 - [13] K. Fujii, „Predictive Analysis and Play Evaluation with Machine Learning”, *Machine Learning in Sports*. Springer Nature Singapore, Singapore, s. 59–84, 2025. doi: 10.1007/978-981-96-1445-5_3.
 - [14] A. Mouri Zadeh Khaki i A. Choi, „Evaluating Fairness in LLM Negotiator Agents via Economic Games Using Multi-Agent Systems”, *Mathematics*, t. 14, nr 3, s. 458, sty. 2026, doi: 10.3390/math14030458.
 - [15] Y. Lu, A. Aleta, C. Du, L. Shi, i Y. Moreno, „LLMs and generative agent-based models for complex systems research”, *Physics of Life Reviews*, t. 51, s. 283–293, grud. 2024, doi: 10.1016/j.plrev.2024.10.013.
 - [16] A. Vidler i T. Walsh, „Playing games with Large language models: Randomness and strategy”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2503.02582>
 - [17] S. Mao *et al.*, „ALYMPICS: LLM Agents Meet Game Theory – Exploring Strategic Decision-Making with AI Agents”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2311.03220>

- [18] N. Lorè i B. Heydari, „Strategic Behavior of Large Language Models: Game Structure vs. Contextual Framing”. Dostęp: 14 marca 2026. [Online]. Dostępne na: <https://arxiv.org/abs/2309.05898>
- [19] I. De Zarzà, J. De Curtò, G. Roig, P. Manzoni, i C. T. Calafate, „Emergent Cooperation and Strategy Adaptation in Multi-Agent Systems: An Extended Coevolutionary Theory with LLMs”, *Electronics*, t. 12, nr 12, s. 2722, cze. 2023, doi: 10.3390/electronics12122722.